

Protocole Scientifique et Modélisation Prédictive : Tunisia Fire Watch

La fiabilité d'une enquête basée sur les données spatiales repose sur la transparence absolue de sa méthodologie. Le modèle prédictif de **Tunisia Fire Watch** s'articule autour d'un algorithme de type Gradient Boosting (XGBoost) alimenté par un croisement de données satellitaires, météorologiques et topographiques.

1. Sources des Données (Open Data et OSINT)

L'entraînement du modèle repose sur un historique géospatial structuré, croisant les foyers d'incendie avérés avec les conditions environnementales antérieures.

- **Vérité Terrain (Target Variable) - NASA FIRMS** : Les occurrences historiques de feux sont extraites des bases de données FIRMS (Fire Information for Resource Management System). Le système exploite les relevés des capteurs **VIIRS** (résolution spatiale de 375 m) et **MODIS** (1 km). La variable cible Y est binaire, où $Y=1$ indique la détection d'une anomalie thermique avec un indice de confiance élevé (Nominal/High), et $Y=0$ représente l'absence d'anomalie.

- **Conditions Météorologiques (Features Dynamiques)** : Les variables climatiques historiques et prédictives (à $J+1$) sont extraites via des API météorologiques ouvertes (comme Open-Meteo). Les variables retenues sont :

- $T_{\max}$: Température maximale journalière (°C).
- H_{mean} : Humidité relative moyenne (%).
- $W_{\max}$: Vitesse maximale du vent (km/h).
- P_{sum} : Cumul des précipitations journalières (mm).

- **Indices Biologiques (Features Statiques/Saisonniers)** : Les données multispectrales issues des satellites Sentinel-2 ou Landsat 8/9 permettent de quantifier la biomasse et le stress hydrique.

- **NDVI (Normalized Difference Vegetation Index)** : Mesure la densité et la santé de la végétation.

$$NDVI = \frac{NIR - RED}{NIR + RED}$$

- **NDWI (Normalized Difference Water Index)** : Évalue la teneur en eau de la végétation (vulnérabilité à la combustion).

$$NDWI = \frac{NIR - SWIR}{NIR + SWIR}$$

(NIR = Proche Infrarouge, RED = Rouge visible, $SWIR$ = Infrarouge à ondes courtes).

- **Topographie (Features Spatiales)** : Le modèle intègre un Modèle Numérique de Terrain (MNT/DEM) tel que SRTM (Shuttle Radar Topography Mission) pour extraire l'altitude (E_m) et le degré de pente, la topographie influençant fortement la propagation des flammes.

2. Ingénierie des Caractéristiques (Feature Engineering)

Avant d'alimenter le modèle, les données brutes subissent un pipeline de transformation spatial et temporel strict :

1. **Maillage Géospatial (Grid Creation)** : Le territoire est découpé en une matrice de mailles hexagonales ou carrées (ex: H3 de Uber ou bounding boxes régulières).

2. **Jointure Spatio-Temporelle** : Pour chaque maille et chaque jour t , les données météorologiques et les indices de végétation sont agrégés. Si un feu est détecté par FIRMS dans cette maille au jour t , la ligne est labellisée $Y=1$.

3. **Gestion du Déséquilibre des Classes (Imbalance)** : Les jours avec incendies (\$Y=1\$) représentent une infime minorité par rapport aux jours sans incendies (\$Y=0\$). Le jeu de données est équilibré soit par suréchantillonnage (SMOTE), soit de manière algorithmique via l'hyperparamètre `scale_pos_weight` de XGBoost, calculé selon le ratio $\frac{N_{\text{negatives}}}{N_{\text{positives}}}$.

3. Modélisation Algorithmique : XGBoost

L'algorithme **eXtreme Gradient Boosting (XGBoost)** a été privilégié en raison de sa performance supérieure sur les données tabulaires hétérogènes et sa capacité à modéliser des relations non linéaires complexes (comme l'interaction entre une forte pente, un vent fort et un faible NDWI).

XGBoost est un ensemble d'arbres de décision construits séquentiellement. À chaque itération t , le modèle ajoute un nouvel arbre f_t qui tente de corriger les erreurs des arbres précédents en minimisant la fonction d'objectif suivante :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

- l représente la fonction de perte (Log Loss pour la classification binaire).
- $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ est le terme de régularisation qui pénalise la complexité de l'arbre pour éviter le surapprentissage (overfitting).

Le modèle génère une probabilité continue $P(Y=1 | X)$ comprise entre 0 et 1. Cette probabilité est traduite dans le dashboard en `risque_prob` (exprimé en pourcentage).

4. Évaluation et Validation Scientifique

L'exactitude (Accuracy) est une métrique trompeuse pour la détection d'incendies en raison du déséquilibre des classes. L'évaluation du modèle repose sur une matrice de confusion analysée à travers les métriques suivantes :

- **Rappel (Recall / Sensibilité)** : La capacité du modèle à identifier correctement tous les feux réels. Un rappel élevé est prioritaire en investigation pour minimiser les faux négatifs (zones à risque ignorées).
- **Précision (Precision)** : La proportion de feux prédits qui se sont réellement déclarés, minimisant ainsi les fausses alertes.
- **F1-Score** : La moyenne harmonique de la précision et du rappel.
- **ROC-AUC (Area Under the Receiver Operating Characteristic Curve)** : Évalue la capacité globale du modèle à distinguer les classes positives et négatives à différents seuils de probabilité.

5. Inférence en Production

En phase d'exploitation (production), le pipeline est exécuté quotidiennement via GitHub Actions. Les prévisions météorologiques à J+1 sont récupérées, croisées avec la topographie et les derniers indices végétatifs, puis injectées dans le modèle XGBoost pré-entraîné. Les probabilités résultantes sont exportées dans le fichier `carte_risques_demain_reel.csv`, prêt à être lu et rendu en 3D par l'interface React / Deck.gl.